Documentación del flujo de procesamiento de facturas

Facturación Inteligente (IA) · Versión 1.0 · 22/10/2026 · Basada en los scripts `procesar_ocr_version.py`, `devolucion_ocr_facturas_version.py`, `extraer_cae_a_excel.py` y `obtener_datos_facturas_cae.py`

1. Objetivo y alcance

El flujo toma las facturas en PDF que están pendientes de contabilizar, las convierte en PDF con texto legible (OCR), identifica el **CAE** de cada una y, a partir de él, obtiene los datos fiscales (empresa receptora, proveedor, tipo, punto de venta, número, importe, moneda, CUIT, vencimiento). El resultado final es un único Excel listo para revisar y cargar: `07. Resultado Final\resultado_facturas_cae.xlsx`.

El flujo se ejecuta en **4 pasos numerados** (más un paso 00 de instalación inicial). Cada paso se lanza con un archivo `.bat` ubicado en la carpeta `98. AUTOMATIZACION` y ejecuta un script de la carpeta `03. Python scripts`.

> ***Nota:*** *los archivos `.bat` no formaban parte del material analizado. Se asume que cada uno invoca al script indicado en la tabla de la sección 3. Esta documentación describe con detalle el comportamiento de los scripts.*

2. Estructura de carpetas

La biblioteca *Facturación Inteligente (IA)* contiene, al mismo nivel, la carpeta de facturas y la carpeta `98. AUTOMATIZACION`. Los scripts calculan todas las rutas a partir de la ubicación de `98. AUTOMATIZACION`, por lo que **no se deben renombrar esas carpetas**.

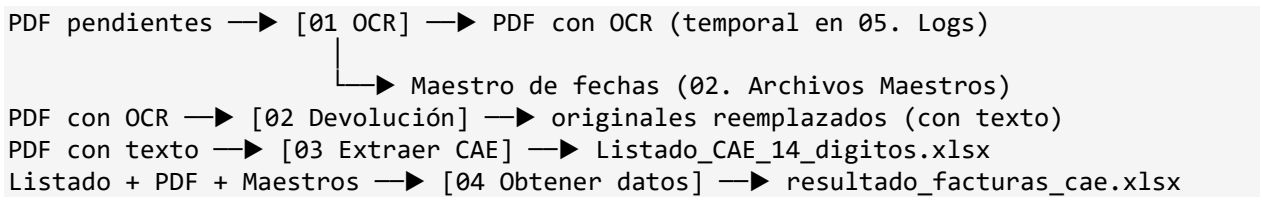
Carpeta / archivo	Contenido y uso
`01. FACTURAS PENDIENTES CONTABILIZAR (AI)`	Fuera de `98. AUTOMATIZACION`, al lado. Contiene los PDF de facturas (admite subcarpetas). Es la única carpeta cuyos PDF se leen y, en el paso 2, se reemplazan.
`98. AUTOMATIZACION\01. Dependencias`	Programas de soporte, en especial `Tesseract` (motor OCR, con `tessdata`).
`98. AUTOMATIZACION\02. Archivos Maestros\Maestro Unificado`	Maestros en Excel: empresas, proveedores y fechas de facturas.
`98. AUTOMATIZACION\03. Python scripts`	Los cuatro scripts del flujo.
`98. AUTOMATIZACION\04. Resultados`	Salidas intermedias: `Listado_CAE_14_digitos.xlsx` y `Estadisticas OCR\ocr_estadisticas.xlsx`.
`98. AUTOMATIZACION\05. Logs`	Logs de cada paso, carpetas temporales

Carpeta / archivo	Contenido y uso
	`OCR_PARA_DEVOLVER_<ID>` y `Historial Devolucion OCR`.
`98. AUTOMATIZACION\06. Documentacion`	Esta documentación.
`98. AUTOMATIZACION\07. Resultado Final`	Salida final del flujo: `resultado_facturas_cae.xlsx`.
`EJEMPLOS ERRORES` y `!!! PENDIENTES ALEX !!!!.txt`	Material de apoyo (casos de error y tareas pendientes). No son leídos por ningún script.

3. Visión general del flujo

Paso	Archivo .bat	Script	Qué hace	Salida principal
00	`00_INSTALA_requisitos_previos_(ejecutar_sólo_la_primera_vez).bat`	—	Instala las dependencias de Python y del entorno.	Entorno listo
01	`01_CONVIERTE_a_TEXTO_los_PDF_usando_OCR.bat`	`procesar_ocr_version.py`	Aplica OCR a los PDF sin texto y registra fechas de recepción.	PDF con OCR en `05. Logs\OCR_PARA_DEVOLVER_<ID>` + Maestro de fechas
02	`02_MUEVE_archivos_TEXTO_a_su_carpeta_original.bat`	`devolucion_ocr_facturas_version.py`	Reemplaza cada PDF original por su versión con OCR, con controles de seguridad.	PDF originales con texto
03	`03_EXTRAER_CAE_A_EXCEL.bat`	`extraer_cae_a_excel.py`	Busca el CAE de 14 dígitos en cada PDF.	`04. Resultados\Listado_CAE_14_digitos.xlsx`
04	`04_OBTENER_DATOS_FACTURAS_CAE.bat`	`obtener_datos_facturas_cae.py`	Lee el QR fiscal / texto y arma el resultado final.	`07. Resultado Final\resultado_facturas_cae.xlsx`

El orden es obligatorio: cada paso usa la salida del anterior.



4. Requisitos previos (Paso 00)

Se ejecuta **una sola vez por equipo**. Los scripts necesitan:

- **Python 3** con las librerías: `pymupdf`, `openpyxl`, `ocrmypdf`, `opencv-python`, `numpy` y `zxing-cpp`.
- **Tesseract** (con idioma español `spa`) en `01. Dependencias\Tesseract\tesseract.exe`. El script busca primero en `01. Dependencias` y, como respaldo, en `Dependencias`. Si no lo encuentra, se detiene e informa las rutas revisadas.
- `ocrmypdf` normalmente requiere además **Ghostscript** instalado en el equipo; conviene verificar que el paso 00 lo contemple.
- **OneDrive/SharePoint**: las carpetas deben estar sincronizadas y marcadas como *Mantener siempre en este dispositivo*, en especial `01. Dependencias`.
- **Windows**: el paso 04 usa `msvcrt` para detectar archivos abiertos.

5. Paso 01 – OCR de los PDF (`procesar_ocr_version.py`)

Objetivo: que todos los PDF de facturas tengan capa de texto, sin tocar los originales.

Funcionamiento

1. Genera un **ID de proceso** `YYYYMMDDHHMMSS` que se graba en todos los registros de la corrida.
2. Verifica que existan `01. FACTURAS PENDIENTES CONTABILIZAR (AI)` y Tesseract.
3. Lista de forma recursiva todos los PDF, ignorando los que terminan en `_OCR.pdf`.
4. **Antes de empezar el OCR**, registra cada factura en el **Maestro de fechas** (ver sección 10), de modo que la información quede guardada aunque se interrumpa el proceso.
5. Para cada PDF decide:
    - Existe `<nombre>_OCR.pdf` junto al original → `OCR_YA_EXISTE`, se omite.
    - Ya existe su OCR en una carpeta `OCR_PARA_DEVOLVER_*` de una corrida anterior → `OCR_EN_CORRIDA_ANTERIOR`, se omite.
    - El PDF ya tiene texto → `CON_TEXTO`, se omite.
    - Sin texto → ejecuta `ocrmypdf --skip-text --rotate-pages --jobs 4 -l spa`. Si termina bien: `OCR_REALIZADO`; si falla: `ERROR` (se borra el archivo incompleto).
6. Los PDF con OCR se guardan en `05. Logs\OCR_PARA_DEVOLVER_<ID>\<misma estructura de subcarpetas>\<nombre>_OCR.pdf`.
7. Muestra un contador de tiempo en vivo y el promedio por PDF.

Detener el proceso: `Ctrl + C`. El script guarda lo realizado y marca la corrida como `INTERRUMPIDO`.

Salidas

Archivo	Ubicación	Contenido
`ocr_log_<ID>.xlsx`	`05. Logs`	Una fila por PDF: Fecha, Archivo, Estado, Detalle, Duración, RutaOrigen, RutaActual, IdProceso.
`ocr_log_<ID>.txt`	`05. Logs`	Los mismos mensajes que se ven en pantalla, con hora.

Archivo	Ubicación	Contenido
`ocr_estadisticas.xlsx`	`04. Resultados\Estadisticas OCR`	Historial acumulativo (una fila por corrida): horas, duración, PDF encontrados, con/sin texto, OCR realizados/existentes, errores.
Maestro de fechas	`02. Archivos Maestros\Maestro Unificado`	Ver sección 10.

Si un Excel está abierto, el script conserva las filas en memoria y reintenta; para las estadísticas crea un respaldo `ocr_estadisticas_PENDIENTE_<ID>.xlsx`.

6. Paso 02 – Devolución del OCR (`devolucion_ocr_facturas_version.py`)

Objetivo: reemplazar cada PDF original por su versión con OCR, **conservando el nombre original**, y dejar una única copia por factura.

Fuente de verdad: los logs `05. Logs\ocr_log_<ID>.xlsx`. Solo se devuelven las filas con estado `OCR_REALIZADO` (también `OCR_PENDIENTE_DEVOLVER`, que se conserva solo por compatibilidad con logs antiguos).

Controles antes de reemplazar un original (si alguno falla, no se toca nada):

- El original sigue **sin texto** (no fue cambiado por otro archivo).
- Original y OCR tienen la **misma cantidad de páginas**.
- El original **no fue modificado** después de generarse el OCR (tolerancia de 5 segundos).
- El OCR se puede abrir y tiene texto reconocible.
- La ruta del original está dentro de `01. FACTURAS PENDIENTES CONTABILIZAR (AI)`.

Reemplazo seguro: se copia el OCR a un temporal junto al original (`.ocr.tmp`), se valida tamaño y páginas y recién entonces se pisa el original con un reemplazo atómico. Si algo falla, el original queda intacto.

Limpieza al terminar

- El PDF OCR se **mueve** (el backup en `05. Logs` se elimina).
- Si existe un `<nombre>_OCR.pdf` junto al original (formato de un proceso anterior) y es **idéntico**, también se elimina.
- Las carpetas `OCR_PARA_DEVOLVER_<ID>` se borran completas; los PDF que no se devolvieron quedan registrados como `BACKUP_DESCARTADO`.
- Verificación final: cuenta los PDF de facturas y detecta `_OCR.pdf` duplicados o sin original.

Uso por línea de comandos

```
python devolucion_ocr_facturas_version.py                  # todas las corridas
python devolucion_ocr_facturas_version.py 20261002094900   # solo esa corrida
python devolucion_ocr_facturas_version.py --simular        # no modifica nada, solo
informa
```

Es seguro ejecutarlo varias veces: un original que ya tiene texto no se vuelve a tocar.

Estados del log de devolución

Estado	Significado
`REEMPLAZADO`	Original sustituido por su versión OCR.
`YA_REEMPLAZADO`	El original ya tiene texto y el backup ya no existe (corrida anterior).
`CONFLICTO_ORIGINAL`	Original con texto, distinto nº de páginas, modificado después del OCR o ilegible. No se toca; revisar.
`OCR_SIN_TEXTO`	El OCR no reconoció texto (hoja en blanco o ilegible). No se reemplaza; revisar.
`ORIGINAL_NO_ENCONTRADO`	El PDF original fue movido, renombrado o borrado.
`OCR_NO_ENCONTRADO`	No se halló el PDF con OCR y el original sigue sin texto.
`SIMULADO`	Resultado del modo `--simular`.
`HUERFANO_EN_BACKUP`	PDF en backup que ningún log reclama.
`DUPLICADO_OCR_JUNTO` / `OCR_SIN_ORIGINAL`	Hallazgos de la verificación final.
`ERROR`	Error de lectura o de proceso; ver detalle.

Salidas (en `05. Logs\Historial Devolucion OCR`): `devolucion_log_<ID>.xlsx`, `devolucion_log_<ID>.txt` y `devolucion_estadisticas_<ID>.txt` (incluye el espacio liberado en MB).

7. Paso 03 – Extracción de CAE (`extraer_cae_a_excel.py`)

Objetivo: generar el listado de CAE (14 dígitos) de todas las facturas.

Funcionamiento

1. Recorre de forma recursiva todos los PDF de `01. FACTURAS PENDIENTES CONTABILIZAR (AI)`. Opcionalmente acepta como argumento otra carpeta de origen.
2. En cada página busca la etiqueta **CAE / C.A.E. / CAF** (tolera el error típico de OCR *CAF*).
3. Busca números de 14 o más dígitos cerca de la etiqueta con tres estrategias: la misma línea, la línea anterior y la siguiente, y una ventana de hasta 2.500 caracteres hacia la derecha y, si no hay resultado, hacia la izquierda.
4. **Valida cada candidato** leyendo de derecha a izquierda: los 14 últimos dígitos son el CAE; el dígito 14 no puede ser `0`; todo lo que queda a la izquierda debe ser ceros. Si no cumple, se descarta.
5. Elimina **duplicados globales**: un mismo CAE se registra una sola vez aunque aparezca en varios PDF.

Salida: `04. Resultados\Listado_CAE_14_digitos.xlsx` con dos hojas.

- **CAE Extraidos:** Nombre de archivo, Ruta completa, Ruta relativa y CAE (formato texto).
- **Log de Eventos:** Timestamp, Archivo, Ruta, Estado y Detalle. Estados: `PROCESADO EXITOSAMENTE`, `DUPLICADO DESCARTADO`, `OMITIDO` (sin texto extraíble o sin CAE válido) y `ERROR LECTURA`.

Un PDF **sin texto** se omite con el mensaje *Requiere OCR*: indica que los pasos 01 y 02 no se completaron para ese archivo. Si el Excel de salida está abierto, el script se detiene con un aviso de acceso bloqueado.

8. Paso 04 – Obtención de datos de las facturas (`obtener_datos_facturas_cae.py`)

Objetivo: completar, para cada CAE del listado, los datos fiscales de la factura y generar el resultado final.

Funcionamiento general

1. **Validación previa:** comprueba que no estén abiertos en Excel el listado, los maestros, el resultado ni el log. Si alguno lo está, no procesa nada y lo informa.
2. Carga los maestros (sección 10) y el listado de CAE únicos.
3. **Indexa los PDF por CAE:** lee el texto de todos los PDF y busca cada CAE (ignorando espacios, puntos y guiones). Si un CAE aparece en varios PDF, procesa el de ruta más corta y lo deja anotado (`CAE_DUPLICADO_EN_PDF`).
4. Para cada CAE intenta leer el **QR fiscal de ARCA/AFIP** (fuente principal y oficial).
5. Si no hay QR utilizable, completa con el **texto del PDF** y el **nombre del archivo**.
6. Calcula el vencimiento y guarda los resultados y los logs.

Lectura del QR: se prueban, en orden, las imágenes embebidas del PDF, el recuadro del QR detectado y renderizado a 200 DPI, y como último recurso la página completa (primeras 3 páginas y la última). Solo se acepta un QR con URL de dominios oficiales (`arca.gob.ar`, `afip.gob.ar`, `servicioscf.afip.gob.ar`) que incluya los campos `cuit`, `ptoVta`, `tipoCmp`, `nroCmp`, `importe`, `moneda` y `codAut`.

8.1 Con QR procesado (`ESTADO_QR = QR_PROCESADO`)

Se toman **exclusivamente los datos del QR**: tipo de comprobante (según el código de ARCA), punto de venta y número (completados con ceros a 5 y 8 dígitos), CUIT emisor, importe, moneda, fecha de emisión y CAE. La fuente de datos es `QR`.

8.2 Sin QR (`ESTADO_QR = QR_NO_PROCESADO`)

Se extrae del texto del PDF (en dos vistas: texto crudo y texto reconstruido por filas) y del nombre de archivo: tipo, punto de venta y número, CUIT del emisor, proveedor, moneda, fecha de emisión e importe verificado. Cada decisión deja una observación cuando hay dudas.

9. Reglas de negocio del Paso 04

Importe (dato sensible). Sale de una sola fuente confiable, por prioridad:

1. QR fiscal de ARCA/AFIP.

2. Sin QR: el **TOTAL** del texto, solo si cierra aritméticamente (es igual a la suma de 2 a 4 montos del mismo documento, con tolerancia de 1 centavo; 1 término en facturas B y C). Se descarta si parece un subtotal (su IVA figura en el documento pero no el total).
3. Si no se puede verificar: `IMPORTE_TOTAL = NO_DETECTADO` y queda la observación *cargar manualmente*. **Nunca se estima el importe.**

Las **notas de crédito** se guardan con importe **negativo**.

Punto de venta y número. Sin QR se informan tal como están impresos (hasta 5 y 8 dígitos), con validaciones y avisos si el formato es inusual, si hay más de un candidato o si difiere del nombre del archivo. El campo `VALIDACION_PTO_NRO` indica cómo se obtuvo: `OK_QR`, `OK_QR_Y_TEXTO`, `OK_QR_Y_TEXTO_ANCLADO`, `QR_SIN_FORMATO_IMPRESO`, `SOLO_TEXTO`, `SOLO_TEXTO_DISCREPA_NOMBRE`, `SOLO_NOMBRE_ARCHIVO` o `NO_DETECTADO`.

Proveedor y CUIT. El CUIT emisor debe existir en el maestro de proveedores; el nombre del proveedor se toma del maestro. Si el CUIT coincide con una empresa receptora se marca `ERROR DE INTEGRIDAD` y se deja el proveedor como no encontrado. Los CUIT se validan por dígito verificador y por prefijo (20, 23, 24, 25, 26, 27, 30, 33, 34, 50, 51, 55). `CUIT_EMISOR_FACTURA` conserva el CUIT leído aunque no esté en el maestro.

Empresa receptora. Se identifica por el CUIT receptor (del QR o del texto) contra el maestro de empresas. Si no se encuentra, se intenta deducir por palabras clave en la ruta o el nombre del archivo (MASAS, BAT → BATATALES, SEMILLERO / _SC, GER → GERMINAGRO, AYERZA); si tampoco, `NO_IDENTIFICADA`.

Moneda. Se normaliza a `ARS` o `USD`. Sin QR y con texto legible pero sin indicación de moneda, se asume `ARS` y se anota.

Vencimiento. En orden de prioridad:

1. Si el nombre del archivo contiene `VTO dd-mm[-aaaa]`, esa es la fecha de vencimiento (`ORIGEN_VENCIMIENTO = NOMBRE_ARCHIVO`).
2. Si no, **fecha de modificación del archivo (tomada del Maestro de fechas) + 28 días** (`MODIFICACION_MAS_28_DIAS`).
3. Si no hay fecha: `NO_CALCULADO` (`SIN_FECHA`).

Control de completitud. Se consideran críticos: tipo, punto de venta, número, importe, moneda, CUIT del maestro, proveedor y empresa receptora. Si alguno falta, la observación lo lista (`FALTAN: …`) y la fila cuenta como incompleta.

9.1 Columnas del resultado final

`EMPRESA_RECEPTORA`, `PROVEEDOR`, `TIPO_COMPROBANTE`, `PUNTO_VENTA`, `NUMERO_COMPROBANTE`, `FECHA_REFERENCIA_VENCIMIENTO`, `FECHA_VENCIMIENTO_CALCULADA`, `ORIGEN_VENCIMIENTO`, `IMPORTE_TOTAL`, `MONEDA`, `CUIT_EMISOR_MAESTRO_DE_PROVEEDORES`, `CUIT_EMISOR_FACTURA`, `CAE`, `NOMBRE_ARCHIVO`, `RUTA_COMPLETA`, `FECHA_MODIFICACION_ARCHIVO`, `ESTADO_QR`, `FECHA_EMISION`, `FUENTE_DATOS`, `OBSERVACIONES`, `VALIDACION_PTO_NRO`.

9.2 Salidas del paso 04

Archivo	Ubicación	Hojas
`resultado_facturas_cae.xlsx`	`07. Resultado Final`	`RESULTADO` (una fila por factura) y `LOG_PROCESO` (resumen de la corrida).
`procesamiento_cae.xlsx`	`05. Logs`	`DETALLE` (una fila por CAE, con estado de búsqueda, QR y observaciones) y `RESUMEN`.

Estados de búsqueda en `DETALLE`: `CAE_ENCONTRADO`, `CAE_NO_ENCONTRADO`, `CAE_DUPLICADO_EN_PDF` y `ERROR_LECTURA_PDF`. El resumen incluye CAE únicos, repetidos en el listado, PDF revisados, filas completas e incompletas, QR procesado / no procesado y faltantes por campo crítico.

> *Estos dos archivos se **regeneran en cada corrida**; si se necesita conservar un resultado, hay que copiarlo antes de volver a ejecutar el paso 04.*

10. Archivos maestros

Se ubican en `02. Archivos Maestros\Maestro Unificado`. El paso 04 lee **todos los `.xlsx`** de esa carpeta (incluidas subcarpetas, ignorando temporales `~$`) y reconoce las columnas por nombre, sin importar tildes ni mayúsculas.

Maestro	Cómo se reconoce	Columnas aceptadas (ejemplos)
Empresas receptoras	El nombre del archivo contiene la palabra `EMPRESA`	CUIT (`CUIT_RECEPTOR`, `CUIT_EMPRESA`, `CUIT`…) y nombre (`EMPRESA`, `SOCIEDAD`, `RAZON_SOCIAL`…)
Proveedores	Cualquier otro maestro con CUIT y nombre	CUIT (`CUIT_PROVEEDOR`, `CUIT_EMISOR`, `CUIT`…) y nombre (`PROVEEDOR`, `RAZON_SOCIAL`, `NOMBRE`…)
Fechas de facturas	Columna `ARCHIVO` más columnas de fecha	`ARCHIVO`, `FECHA_RECEPCION`, `FECHA_MODIFICACION_ARCHIVO`

Maestro de fechas (`MAESTRO_FECHAS_FACTURAS.xlsx`): lo mantiene el paso 01. Es **acumulativo y nunca se sobrescribe**; solo agrega facturas nuevas. Columnas: `ARCHIVO`, `RUTA_COMPLETA`, `FECHA_RECEPCION` (creación del archivo en Windows), `FECHA_MODIFICACION_ARCHIVO`, `FECHA_ULTIMO_ACCESO` y `FECHA_PROCESAMIENTO`. La clave de control es *archivo + ruta completa*. Se escribe de forma atómica (archivo temporal y reemplazo) y, si su encabezado no es el esperado, el script no lo modifica. Si todavía existe el maestro de la ubicación anterior (`04. Resultados\Maestro de Fechas`), se migra una sola vez.

Este maestro es clave: como el paso 02 reemplaza los originales (y por lo tanto cambia sus fechas), el maestro conserva la **fecha original del archivo**, que luego se usa para calcular el vencimiento.

Mantenimiento: cuando se incorpora un proveedor o una empresa nueva, se agrega al maestro correspondiente. Un CUIT ausente genera `NO_ENCONTRADO_EN_MAESTRO`.

11. Logs y trazabilidad

Todos los logs se guardan en `05. Logs` (salvo las estadísticas de OCR) y llevan el **ID de proceso** `YYYYMMDDHHMMSS` en el nombre, de modo que cada corrida es identificable y no pisa a las anteriores.

Paso	Registro	Ubicación
01 OCR	`ocr_log_<ID>.xlsx` y `.txt`	`05. Logs`
01 OCR	`ocr_estadisticas.xlsx` (acumulativo)	`04. Resultados\Estadisticas OCR`
02 Devolución	`devolucion_log_<ID>.xlsx`, `.txt` y `devolucion_estadisticas_<ID>.txt`	`05. Logs\Historial Devolucion OCR`
03 Extraer CAE	Hoja `Log de Eventos` dentro del listado	`04. Resultados\Listado_CAE_14_digitos.xlsx`
04 Obtener datos	`procesamiento_cae.xlsx` (se regenera) y hoja `LOG_PROCESO`	`05. Logs` y `07. Resultado Final`

12. Guía de operación

Antes de empezar

1. Confirmar que OneDrive terminó de sincronizar las facturas nuevas y la carpeta `01. Dependencias`.
2. Cerrar todos los Excel de `04. Resultados`, `05. Logs`, `07. Resultado Final` y `02. Archivos Maestros`.
3. Verificar que los maestros de empresas y proveedores estén actualizados.

Ejecución (en este orden)

1. `01_CONVIERTE_a_TEXTO_los_PDF_usando_OCR.bat`: esperar el resumen final. Revisar que `Errores` sea 0.
2. `02_MUEVE_archivos_TEXTO_a_su_carpeta_original.bat`: revisar en el resumen los conflictos, los OCR sin texto y los huérfanos. Se recomienda una primera pasada con `--simular` cuando haya dudas.
3. `03_EXTRAER_CAE_A_EXCEL.bat`: revisar la hoja `Log de Eventos` y los PDF `OMITIDO`.
4. `04_OBTENER_DATOS_FACTURAS_CAE.bat`: abrir `07. Resultado Final\resultado_facturas_cae.xlsx`.

Revisión del resultado final

- Filtrar la columna `OBSERVACIONES` y revisar toda fila con `FALTAN:`, `IMPORTE sin verificar`, `ERROR DE INTEGRIDAD` o avisos de punto de venta / número.
- Verificar los valores `NO_DETECTADO`, `NO_IDENTIFICADA` y `NO_ENCONTRADO_EN_MAESTRO`, y completarlos a mano o actualizando los maestros y volviendo a ejecutar el paso 04.

- Priorizar la revisión de las filas con `ESTADO_QR = QR_NO_PROCESADO`, porque dependen del texto del PDF.
- Antes de volver a ejecutar el paso 04, copiar el resultado si se quiere conservar (se regenera completo).

13. Solución de problemas

Síntoma	Causa probable	Qué hacer
Paso 01 termina con *no se encontró Tesseract*	`01. Dependencias\Tesseract` no está sincronizada o no existe	Esperar la sincronización de OneDrive y marcar la carpeta como *Mantener siempre en este dispositivo*.
Aviso *no se pudo escribir … (está abierto en Excel?)*	Un log o maestro está abierto	Cerrar el archivo; el script reintenta o lo registra en la próxima corrida.
Paso 02: `CONFLICTO_ORIGINAL`	El original cambió después del OCR, o ya tenía texto, o difiere en páginas	Revisar el archivo a mano. No se modificó nada.
Paso 02: `OCR_SIN_TEXTO`	Hoja en blanco o escaneo ilegible	Revisar el PDF; conviene reemplazarlo por un escaneo mejor.
Paso 02: `ORIGINAL_NO_ENCONTRADO`	El PDF fue movido o renombrado entre el paso 01 y el 02	Evitar mover archivos entre pasos; volver a ejecutar el paso 01.
Paso 03: `OMITIDO – Requiere OCR`	El PDF sigue sin texto	Repetir pasos 01 y 02 para ese archivo.
Paso 03: `Ningún CAE válido localizado`	El CAE no se leyó bien o el comprobante no lo tiene	Revisar el PDF; si el OCR es deficiente, volver a escanear.
Paso 04: *NO SE PUEDE INICIAR EL PROCESO*	Hay archivos abiertos en Excel	Cerrar los archivos que lista el mensaje y volver a ejecutar.
Paso 04: `CAE_NO_ENCONTRADO`	El CAE del listado no figura en la capa de texto de ningún PDF	Verificar que los pasos 01–03 estén completos y el PDF no se haya movido.
Paso 04: `QR_NO_PROCESADO`	QR ilegible o ausente	Los datos salen del texto; revisar observaciones.
Proveedor `NO_ENCONTRADO_EN_MAESTRO`	CUIT no cargado en el maestro de proveedores	Agregar el proveedor al maestro y volver a ejecutar el paso 04.

Síntoma	Causa probable	Qué hacer
Vencimiento `NO_CALCULADO`	La factura no está en el Maestro de fechas y el nombre no tiene `VTO`	Volver a ejecutar el paso 01 para registrar la fecha o completar a mano.

14. Observaciones y puntos a revisar

Durante el análisis de los scripts se detectaron los siguientes puntos. No impiden el funcionamiento actual, pero conviene tenerlos presentes o corregirlos.

1. **Punto de venta y número con QR.** El encabezado del script describe que, si el QR y el texto coinciden, se informa el texto literal tal como está impreso. En el código, cuando el QR es válido siempre se completan los ceros a 5 y 8 dígitos y no se consulta el texto (la lógica de formato impreso solo se aplica en el caso sin QR). Conviene confirmar cuál es el criterio deseado.
2. **Empresa receptora por palabras clave.** El respaldo por nombre de archivo o ruta usa fragmentos fijos en el código (MASAS, BAT, SEMILLERO, _SC, GER, AYERZA). Los fragmentos cortos (`BAT`, `GER`) pueden dar falsos positivos, y una empresa nueva requiere modificar el script.
3. **Búsqueda de fechas por nombre de archivo.** En el paso 04 la fecha de modificación se busca solo por nombre de archivo; dos facturas con el mismo nombre en carpetas distintas comparten fecha. El maestro de fechas, en cambio, usa archivo + ruta.
4. **Vencimiento fijo de 28 días.** El plazo está escrito en el código. Si cambia la política de pago, hay que modificarlo en el script.
5. **Parámetro sin uso aparente.** `PERMITIR_CUIT_FUERA_MAESTRO` está definido en la configuración del paso 04, pero no se observa que se utilice.
6. **Resultados que se regeneran.** `resultado_facturas_cae.xlsx` y `procesamiento_cae.xlsx` se sobrescriben en cada corrida; no hay histórico automático.
7. **Un mismo CAE en varios PDF.** El paso 03 descarta el duplicado y el paso 04 procesa solo un PDF por CAE; el resto queda indicado en las observaciones.
8. **Dependencia de OneDrive.** Varias operaciones (borrado de carpetas, reemplazo de archivos, maestros) pueden fallar mientras OneDrive sincroniza; los scripts reintentan o avisan, pero conviene ejecutar el flujo sin sincronizaciones pendientes.
9. **Documentación de los `.bat`.** Esta versión no incluye el detalle de los archivos `.bat`; si pasan parámetros (por ejemplo `--simular` o un ID de corrida) deberían documentarse aquí.

15. Glosario

Término	Significado
CAE	Código de Autorización Electrónico de 14 dígitos que ARCA/AFIP asigna a cada comprobante.
ARCA / AFIP	Organismo fiscal argentino; sus facturas incluyen un QR con los datos oficiales.
OCR	Reconocimiento óptico de caracteres: convierte una imagen escaneada en

Término	Significado
	texto buscable.
QR fiscal	Código QR de la factura cuya URL contiene, codificados, CUIT, punto de venta, tipo, número, importe, moneda y CAE.
Maestro	Planilla Excel de referencia (empresas, proveedores, fechas).
ID de proceso	Identificador `YYYYMMDDHHMMSS` de cada ejecución.
NC / ND	Nota de crédito / nota de débito.
Backup OCR	Carpeta temporal `OCR_PARA_DEVOLVER_<ID>` con los PDF con OCR pendientes de reemplazar a su original.